Fever-Lens

Dónde invertir el presupuesto publicitario de eventos culturales sin abandonar las ciudades con menos actividad

Alexandra Cáceres Ayala Proyecto integrador · Bootcamp de Análisis de Datos · Agosto de 2026

1 · Resumen

Analicé cómo se decide la inversión publicitaria en seis eventos culturales repartidos por España, y encontré que **el indicador con el que se toma esa decisión no mide lo que dice medir**.

Lo que encontré

Definí el ROAS de mi catálogo como `precio de la entrada ÷ coste publicitario`, que es como suele calcularse cuando no se dispone de datos de conversión. La fórmula está a la vista en la hoja de cálculo.

Al analizarlo con el embudo real caí en lo que ese cálculo esconde: **no contiene ningún dato de demanda.** No sabe cuánta gente mira el evento ni cuánta compra: mide el precio.

La consecuencia se ve al comparar esa clasificación con el comportamiento real:

Evento	Clasificación actual	Conversión real
Torneo de Baloncesto ACB	`REVISAR`	**6,90 %**
Monólogo de Comedia	`REVISAR`	**6,25 %**
Musical El Rey León	`RENTABLE`	5,76 %
Concierto Candlelight	`RENTABLE`	5,57 %
Exposición Van Gogh	`ESTRELLA`	4,38 %
Festival de Jazz	`RENTABLE`	**3,83 %**

Los dos eventos marcados para revisión son los que mejor convierten. El peor de los seis está marcado como rentable.

Los otros tres hallazgos

Cada evento falla en un punto distinto del embudo. El Festival de Jazz es el peor convirtiendo visitas en carritos (4,74 %) y el mejor cerrando compras desde el carrito (80,8 %). No le sobra presupuesto: le falta

llegar al público adecuado. Una recomendación que no distinga los dos tramos no sirve para actuar.

El tráfico y la conversión van al revés a lo largo del día. La franja de 08:00 a 13:00 genera 2,26 veces más compras que la de 16:00 a 20:00, y con más tráfico. El pico de visitas —las 17:00— es de las peores horas para convertir.

La renta no explica dónde hay programación. Correlación de Pearson r = 0,535 con p = 0,111: con diez ciudades no puedo afirmar la relación. Y los datos la contradicen: Sevilla programa con 12.404 € por persona, y por encima de ella hay tres ciudades más ricas —Valencia, Gijón y Pamplona— que no tienen ningún evento.

La recomendación

Cuatro de los seis formatos se sostienen en un recinto sin historial **incluso suponiendo la peor demanda que he medido**. Una exposición inmersiva necesitaría solo el **24 % de la demanda media** para devolver cada euro invertido.

Mi proyecto nacía de una tensión entre eficiencia y equidad territorial. Los datos dicen que esa tensión es en buena parte falsa: el criterio actual no está midiendo eficiencia, y activar un recinto apagado no exige apostar fuerte.

No hace falta elegir entre rentabilidad y equidad. Hace falta dejar de decidir con un indicador que no mide lo que dice medir.

---

2 · El problema

Fever es una plataforma internacional de descubrimiento y venta de entradas para eventos culturales. Sitúo el proyecto en **España**, sobre diez recintos reales.

Hay eventos que devuelven 4,11 € por cada euro invertido y otros que devuelven 1,11 €, con costes publicitarios parecidos. La respuesta evidente —invertir donde más rinde— concentra toda la actividad en Madrid y Barcelona, y crea una profecía autocumplida:

```
no invierto en Murcia  →  no hay eventos  →  no hay datos  →  nunca invierto
```

De los diez recintos que analizo, **cuatro no tienen ningún evento programado**: Pamplona, Valencia, Murcia y Gijón. No significa que hayan fracasado, sino que nunca se les ha dado la oportunidad de generar datos.

Las cuatro preguntas que respondo

1. ¿Qué eventos merecen más inversión?
2. ¿A qué hora convierte mejor el tráfico?

3. ¿Explica la renta dónde hay oferta cultural?
4. ¿Qué haría falta para activar un recinto sin actividad?

Lo que no hago

No proyecto escenarios futuros ni entreno ningún modelo. Es un análisis descriptivo, diagnóstico y prescriptivo: describe lo que ocurrió en octubre de 2019, explica por qué, y propone qué hacer. No afirma qué va a pasar.

---

3 · Los datos

Las tres fuentes

Fuente	Qué aporta	Volumen
Catálogo propio (Google Sheets)	Recintos y eventos, con precios y coste publicitario	10 + 6
INE — Atlas de Renta de los Hogares	Renta neta media por persona y municipio	3.009.312 → 90
Kaggle — comportamiento en e-commerce	Vistas, carritos y compras, octubre de 2019	42.448.764

Total: 45.458.092 filas cargadas desde las tres fuentes, más las 90 que derivo del INE al filtrar.

Qué es real y qué construí yo

Fever publica sus eventos, ciudades y precios en su web. Lo que no publica —como ninguna empresa— es precisamente lo que necesita este análisis: el coste publicitario de cada campaña, el rendimiento de esa inversión y el tráfico web. Por eso el catálogo de partida es propio.

Dato	Origen
Los 10 recintos y sus coordenadas	Reales, verificados uno a uno
Los eventos	Tipos de producto que Fever comercializa de verdad
Aforo y precio de entrada	Valores plausibles, definidos por mí
`coste_ad_medio`, `roas`, `estado_inversion`	**Construidos por mí**
Los cuatro recintos sin actividad	**Escenario que diseñé**, no un hallazgo

Google Sheets me sirvió además como **capa de validación**. En la hoja `dashboard interactivo` calculé los promedios de ROAS por ciudad y por categoría, y esos números fueron los valores esperados contra los que contrasté después los resultados de SQL. Si no coincidían, sabía que había un error en la carga o en algún cruce.

El libro está disponible aquí: [Base de datos FEVER]

Consultarlo en Google Sheets y no en una descarga tiene un motivo: la hoja `dashboard interactivo` usa funciones propias de Sheets que no existen en Excel, y en un `.xlsx` deja de funcionar.

Data Mocking: cómo obtengo el comportamiento

Fever no publica su tráfico web, así que tomo prestado el de un e-commerce real y lo asigno a cada evento. **Declaro esa correspondencia en una tabla puente auditable en lugar de camuflarla**: cualquiera puede ver qué producto representa a qué evento y cuestionarlo.

El criterio de asignación lo fijé el 4 de agosto, antes de mirar los datos, y lo dejé escrito: el producto con más tráfico va al recinto de mayor aforo, el segundo con el segundo, y así hasta el sexto.

Descarté emparejar por ROAS porque sería circular —daría más tráfico al evento que ya rinde mejor, construyendo el resultado que quiero demostrar— y por precio porque en mis datos el precio y el ROAS van de la mano. El aforo no predice el rendimiento, y por eso sirve.

Producto de Kaggle	Interacciones	Evento asignado	Aforo
1004856	500.354	Torneo de Baloncesto ACB	60.000
1004767	438.232	Musical El Rey León	17.960
1005115	355.786	Festival de Jazz	10.014
1004833	237.545	Monólogo de Comedia	8.500
1004249	231.070	Exposición Van Gogh	5.000
1004870	220.501	Concierto Candlelight	1.992

Por qué octubre de 2019

Es el único mes del dataset sin Black Friday, sin campaña de Navidad y sin pandemia. Descarté abril de 2020 pese a ser más reciente: coincide con el confinamiento, con el comercio electrónico disparado y con todos los eventos presenciales cancelados, que es justo lo que estudio.

---

4 · Estructura técnica

El flujo

```
MySQL              Python                Power BI
─────              ──────                ────────
carga              embudo                modelo en estrella
limpieza           patrón horario        12 medidas DAX
validación   →     correlación      →    3 páginas
7 tablas           escenario
1 vista            4 CSV exportados
```

Python lee **directamente de MySQL** con las credenciales en un archivo `.env` excluido del repositorio: no hay ningún paso manual entre una herramienta y otra. Power BI se alimenta de cuatro ficheros que exporta el propio cuaderno, ya con la hora convertida y las métricas calculadas.

El modelo de datos en MySQL

Siete tablas y una vista, con **3 claves foráneas, una clave primaria compuesta, una restricción `UNIQUE`, 11 validaciones `CHECK` y 3 índices**.

Tabla	Tipo	Filas	Papel
`dim_recintos`	Dimensión	10	Recintos, coordenadas y código INE
`dim_eventos`	Dimensión	6	Catálogo de productos publicitarios
`dim_renta_ine`	Dimensión satélite	90	Renta por municipio y año. **Sin FK**
`map_mocking`	Puente	6	Traduce Fever ↔ Kaggle
`stg_renta_ine`	Staging	3.009.312	Zona de carga del INE
`stg_interacciones`	Staging	42.448.764	Zona de carga de Kaggle
`fact_interacciones`	**Hechos**	1.983.488	Interacciones de los productos mapeados
`v_recintos_eventos_renta`	**Vista**	10	Recintos + eventos + renta 2019

El grano de `dim_eventos` es un espectáculo en un recinto, entendido como producto publicitario único.

Las dos tablas `stg_` son zonas de espera: reciben los ficheros en crudo y de ellas se derivan las del modelo. Son necesarias porque `LOAD DATA` no admite filtrar al cargar.

El modelo en estrella de Power BI

```
        dim_recinto (10)
              │  nombre_recinto
              ▼
        dim_evento (6)
              │  product_id
              ▼
    fact_evento_hora (144)
              ▲
              │  hora
         dim_hora (24)
```

Tres relaciones, todas **varios a uno y de dirección única**, sin ambigüedad. Las doce medidas DAX se detallan en el documento anexo, e incluyen `AVERAGEX`, `SUMX` con `RELATED`, `CALCULATE` con `ALL` y `DISTINCTCOUNT`.

Optimización, medida

La consulta que selecciona los productos recorre 42 millones de filas. La cronometré antes y después de crear un índice sobre la columna de agrupación, tres ejecuciones cada vez y en las mismas condiciones:

Momento	Ejecuciones	Media
Sin índice	7,483 · 7,525 · 7,435 s	**7,481 s**
Con índice	3,832 · 3,804 · 3,820 s	**3,819 s**

Mejora de 1,96× (−49 %). Crear el índice costó 12,380 s una sola vez, y cada consulta ahorra 3,662 s: **se amortiza en la cuarta ejecución**.

Creé la tabla de staging deliberadamente **sin índices ni restricciones** para no ralentizar la carga de 42 millones de filas, e indexé después. Los 42.448.764 registros entraron en 73,4 segundos con cero avisos.

---

5 · Los análisis

5.1 · ¿Qué eventos merecen más inversión?

El ROAS de mi catálogo se calcula como `precio ÷ coste`, y esa fórmula no incorpora demanda en ningún punto. Añado la que falta:

```
ROAS ajustado = ROAS reportado × índice de demanda
```

Donde el índice es la tasa de conversión del evento dividida entre la media de los seis. Uso el índice **relativo** y no la tasa absoluta porque mis productos vienen de un e-commerce: al dividir entre la media, esa distorsión se cancela y queda la diferencia entre eventos, que sí es información válida.

Evento	Clasificación	ROAS reportado	Índice	ROAS ajustado	Puesto
Exposición Van Gogh	ESTRELLA	4,11	0,80	**3,31**	1 → 1
Concierto Candlelight	RENTABLE	2,50	1,02	**2,56**	2 → 2
Musical El Rey León	RENTABLE	2,14	1,06	**2,26**	3 → 3
Torneo de Baloncesto	REVISAR	1,25	1,27	**1,58**	5 → **4** ▲
Monólogo de Comedia	REVISAR	1,11	1,15	**1,27**	6 → **5** ▲
Festival de Jazz	RENTABLE	1,80	0,70	**1,26**	4 → **6** ▼

El Festival de Jazz cae de cuarto a sexto y queda por debajo de los dos eventos marcados para revisión. Cada movimiento de puesto es un evento sobre el que se estaría decidiendo con información incompleta.

5.2 · ¿Dónde se pierde la gente?

Una tasa global dice cuánta gente se pierde, pero no dónde. Y no es lo mismo perderla antes del carrito —falta de interés— que después —precio, confianza o fricción al pagar—.

Evento	Vista → Carrito	Carrito → Compra
Torneo de Baloncesto	12,43 %	55,5 %
Monólogo de Comedia	10,75 %	58,2 %
Concierto Candlelight	10,21 %	54,6 %
Musical El Rey León	9,94 %	57,9 %
Exposición Van Gogh	7,02 %	62,4 %
Festival de Jazz	**4,74 %**	**80,8 %**

El Jazz es el **peor** del primer tramo y el **mejor** del segundo. Quien se interesa por él compra; el problema es que se interesan muy pocos. Eso no se arregla bajando el precio: se arregla llegando a otro público.

5.3 · ¿A qué hora convierte mejor el tráfico?

Las marcas de tiempo del dataset están en UTC. En octubre de 2019 España iba dos horas por delante hasta el día 27 y una desde el 27, así que las convertí a hora peninsular antes de agrupar, usando el identificador de zona horaria y no un desfase fijo: el identificador incorpora la regla del cambio de hora.

Franja	Vistas	Compras	Conversión
08:00 – 13:00	605.242	**42.611**	**7,04 %**
16:00 – 20:00	497.494	18.849	3,79 %

La franja de mañana genera **2,26 veces más compras** que la de tarde, y con más tráfico. El pico absoluto de visitas son las 17:00 (115.770), y es de las peores horas para convertir: 3,87 %. La mejor es las 11:00, con 7,30 %.

Si el presupuesto se reparte siguiendo el volumen de tráfico, se está pagando por llegar a la audiencia que menos compra.

5.4 · ¿Explica la renta dónde hay oferta cultural?

Indicador	Valor
Coeficiente de correlación	**r = 0,535**
p-valor	**0,111**
Umbral convencional	0,05

El p-valor de 0,111 significa que, si no existiera ninguna relación, aún así vería una asociación así de fuerte **una de cada nueve veces** por azar. Con diez ciudades no tengo material para descartarlo.

La diferencia de medias existe —15.152 € en los recintos con evento frente a 13.298 € en los que no—, pero los propios datos la contradicen:

Ciudad	Renta 2019	¿Programa?
Madrid	17.030 €	Sí
Barcelona	16.894 €	Sí
Bilbao	16.119 €	Sí
Burgos	14.351 €	Sí
Zaragoza	14.116 €	Sí
Pamplona	**14.106 €**	**No**
Gijón	13.810 €	No
Valencia	13.643 €	No
Sevilla	**12.404 €**	**Sí**
Murcia	11.631 €	No

Sevilla programa con 12.404 €, y por encima de ella hay tres ciudades más ricas que no programan: Valencia, Gijón y Pamplona. Pamplona tiene 1.702 € más de renta por persona que Sevilla, y su recinto está vacío.

La ciudad con menor renta de las diez es **Murcia**, con 11.631 €, y tampoco tiene actividad. Pero si la renta mandara, Sevilla tendría que estar tan parada como ella — y no lo está.

Mi tesis de partida era que la programación se concentra donde hay más poder adquisitivo. Los datos apuntan en esa dirección pero **no la sostienen**, y prefiero decirlo antes que forzar la conclusión que me convenía. Lo que sí queda demostrado es que **la renta no basta para explicar el reparto**.

5.5 · ¿Qué haría falta para activar un recinto sin actividad?

Tomo **Murcia**, el recinto con menor renta de los cuatro parados y por tanto el más difícil de defender con el criterio actual.

Un evento se sostiene cuando su ROAS ajustado llega a 1. Despejando de la misma fórmula del apartado 5.1, la demanda mínima que necesita es `1 ÷ ROAS reportado`. No añado ningún supuesto nuevo.

Formato	Índice necesario	¿Aguanta la peor demanda observada (0,70)?
Exposición inmersiva	**0,24**	Sí
Concierto Candlelight	0,40	Sí
Musical	0,47	Sí
Festival de jazz	0,56	Sí
Torneo deportivo	0,80	No
Monólogo	0,90	No

Cuatro de los seis formatos se sostienen en Murcia incluso suponiendo la peor demanda medida en todo el análisis. Una exposición inmersiva necesitaría solo el 24 % de la demanda media.

El motivo es aritmético, no de gustos: los formatos con entrada cara respecto a su coste de captación —la inmersiva son 185 € frente a 45 €— aguantan mucha menos demanda antes de dejar de compensar.

---

6 · Recomendaciones

1. Dejar de clasificar la inversión con el ROAS actual. Mide el precio de la entrada, no el rendimiento. Sustituirlo por el ROAS ajustado, que incorpora la conversión real, cambia el puesto de tres de los seis eventos.

2. Diagnosticar cada evento por tramo del embudo, no por una tasa global. Al Festival de Jazz no le sobra presupuesto: le falta alcance. Un recorte de inversión —lo que sugeriría una lectura superficial—

agravaría exactamente el problema que tiene.

3. Concentrar la inversión publicitaria en la franja de mañana. De 08:00 a 13:00 se compra 2,26 veces más que de 16:00 a 20:00, con más tráfico además. Repartir el presupuesto siguiendo el volumen de visitas es pagar por la audiencia que menos convierte.

4. Para activar un recinto sin historial, elegir el formato antes que la ciudad. La renta no explica el reparto actual. Lo que sí determina el riesgo es el margen por entrada: un formato de entrada cara y coste de captación bajo se sostiene en Murcia con el 24 % de la demanda media. Probar sale barato — y probar es la única forma de generar los datos que hoy no existen y que perpetúan que Murcia nunca reciba inversión.

---

7 · Limitaciones que declaro

Limitación	Alcance
Mis seis productos convierten al 5,54 % vista→compra frente al 1,82 % del catálogo completo. Al elegirlos por tráfico heredé los que mejor convierten	Las tasas **absolutas** no son representativas. Las comparaciones **entre mis seis eventos** sí lo son: todos parten de la misma distorsión
El comportamiento procede de una tienda que no es el mercado español de Fever	El patrón horario es la **forma de la curva**, no una hora exacta que copiar. Lo trasladable es el método
Diez ciudades para la correlación con la renta	r = 0,535 y p = 0,111: insuficiente para afirmar **o descartar** la relación. Haría falta ampliar a todos los municipios donde Fever opera
`coste_ad_medio`, `roas` y `estado_inversion` los construí yo	El método es real; los valores de partida, no
Los cuatro recintos sin actividad son un escenario que diseñé	Es la premisa del trabajo, no un hallazgo en los datos
`LOAD DATA INFILE` exige rutas absolutas	Los scripts contienen una ruta local que hay que sustituir. Es una limitación de MySQL, no una decisión de diseño

---

8 · Decisiones y aprendizajes

Las decisiones que más condicionaron el trabajo

Descarté mi primer `ddl.sql` entero. Lo había escrito sin poder explicar por qué cada tabla era como era. Preferí empezar de nuevo y poder defender cada línea antes que conservar algo que funcionaba sin entenderlo.

Cruzo con el INE por código de municipio, no por nombre. Al inspeccionar el fichero encontré dos problemas. Hay **seis municipios españoles llamados "Valencia"**, y solo uno es la ciudad que me interesa. Y el INE publica los nombres en su forma oficial: la ciudad aparece como `València`, Pamplona como `Pamplona/Iruña`. Tres de mis diez ciudades no coincidían literalmente. Un `JOIN` por nombre no me habría dado ningún error: **habría perdido esas filas en silencio**.

Represento la ausencia de eventos con `NULL`, nunca con `0`. Un cero afirmaría que hubo inversión y no retornó. Lo comprobé: con ceros, el ROAS medio caía de 2,15 a 1,29, fingiendo un fracaso que no ocurrió.

Fijé el criterio del mocking antes de ver los datos. Podría haber emparejado por ROAS y obtener un resultado más vistoso. Habría sido circular: construir el resultado que quería demostrar.

Las dificultades

Abrí el fichero de Kaggle con Excel y lo trunqué sin darme cuenta. Una hoja de cálculo se para en 1.048.575 filas y no avisa: pasé de 42 millones a uno sin enterarme.

Lo detecté porque el embudo salía al revés: más compras que carritos, algo imposible. Volví a descargarlo y recuperé los 42.448.764 registros.

Lo que aprendí no va de Excel: **un dato corrupto no da error.** Solo se detecta si compruebas que los números tienen sentido entre sí.

Dimensioné una tabla por suposición y salieron 1.024 avisos de truncamiento. Puse `VARCHAR(20)` en dos columnas dando por hecho que eran códigos cortos. Medidas sobre el fichero: 68 y 74 caracteres. Lo corregí a `VARCHAR(150)` y recargué hasta cero avisos.

Ahí aprendí que **un aviso es más peligroso que un error**: el error para el proceso, el aviso lo deja continuar con los datos ya estropeados.

Probar una restricción `CHECK` no fue tan fácil como esperaba. Intenté insertar un año imposible para comprobar que la defensa funcionaba, y en vez del error que esperaba salió otro distinto: el tipo de dato había rechazado el valor antes de que el `CHECK` llegara a evaluarlo. Descubrí que las defensas están en cadena y se comprueban en orden.

Lo que me llevo

Que **verificar no es desconfiar de la herramienta, es parte del trabajo**. Cada carga la comprobé con recuentos, no con el color del mensaje. Cada cifra de este informe está contrastada contra su fuente. Y los números de MySQL, Python y Power BI coinciden entre sí porque los comparé, no porque lo diera por hecho.

Y que **decir "no puedo afirmarlo" es un resultado**. La correlación con la renta era mi hipótesis de partida y no salió significativa. Declararlo vale más que forzar una conclusión que los datos no sostienen.

---

9 · Cómo reproducir el trabajo

Requisitos

- **MySQL 8.0.16 o superior.** Por debajo, las restricciones `CHECK` se aceptan pero no se evalúan.
- `LOAD DATA LOCAL INFILE` habilitado en servidor y cliente.
- Python con `pandas`, `numpy`, `matplotlib`, `seaborn`, `scipy`, `sqlalchemy`, `pymysql` y `python-dotenv`.
- Power BI Desktop.

Dónde están los datos de origen

El catálogo propio sí está en el repositorio: `Recintos Base de datos FEVER.csv` y `Eventos Base de datos FEVER.csv`, junto al libro original en `.xlsx`. Pesan unos kilobytes. El libro vivo está enlazado en la sección 3.

Las otras dos fuentes suman 7,2 GB y GitHub no admite archivos de más de 100 MB, así que quedan fuera:

Kaggle — dataset *eCommerce behavior data from multi category store*, de mkechinov. El mes que analizo es `2019-Oct.csv`, 1,62 GB comprimido.

INE — *Atlas de Distribución de Renta de los Hogares*, fichero *1. Indicadores de renta media y mediana*, en CSV separado por tabuladores. En mi proyecto es `30824.csv`.

Mis sentencias `LOAD DATA` apuntan a esos dos nombres y a una ruta absoluta de mi equipo, indicada en la cabecera de `analisis.sql`.

Sobre la integridad del fichero de Kaggle

Una hoja de cálculo trunca ese CSV en **1.048.575 filas sin avisar**, y lo guarda como si estuviera entero. El fichero íntegro tiene **42.448.764 filas** y cubre del 1 al 31 de octubre de 2019.

La comprobación que de verdad delata un fichero incompleto es el **embudo**: los carritos tienen que superar a las compras.

Tipo de evento	Proporción esperada
`view`	96,07 %
`cart`	2,18 %
`purchase`	1,75 %

Si aparecen más compras que carritos, faltan filas. Así detecté yo la primera descarga defectuosa.

Cómo dependen los entregables entre sí

1. **Google Sheets** — construí ahí el catálogo de recintos y eventos y lo exporté a CSV. También calculé con tablas dinámicas los promedios que después usé como valores esperados al validar la carga.
2. `ddl.sql` — crea el esquema, las siete tablas y la vista.
3. `analisis.sql` — carga las tres fuentes, limpia, valida y analiza. Necesita el paso 2.
4. `analisis.ipynb` — responde las cuatro preguntas y exporta los CSV del modelo de Power BI. Necesita la base de datos ya poblada.
5. `dashboard.pbix` — el panel de tres páginas, construido sobre los CSV que exporta el paso 4. Lleva los datos dentro, así que para abrirlo no hace falta recorrer la cadena.

Fever-Lens · Alexandra Cáceres Ayala · Agosto de 2026